

Министерство образования и науки Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего
профессионального образования
«Московский физико-технический институт (государственный университет)»
Факультет инноваций и высоких технологий
Кафедра анализа данных

На правах рукописи
УДК ????

Левков Мирон Николаевич

Гладкая метрика для задачи ранжирования

Выпускная квалификационная работа бакалавра

Направление подготовки: 010400 Прикладные математика и информатика

Заведующий кафедрой
Научный руководитель
Студент

/Бунина Е.И./
/Воронцов А.С./
/Левков М.Н./

г. Москва
2017

Гладкая метрика для задачи ранжирования

М.Н. Левков

АННОТАЦИЯ. Рассматривается задача ранжирования документов в поисковых запросах. В работе исследованы имеющиеся варианты сглаживания метрики ранжирования. Предложены различные способы сглаживания метрики DCG. Проведен анализ зависимости качества сглаженных метрик от гиперпараметров и размера выборки поисковых запросов.

СОДЕРЖАНИЕ

| | | |
|-----|---|----|
| 1 | Введение | 2 |
| 1.1 | Описание задачи ранжирования | 2 |
| 1.2 | Обозначения | 2 |
| 2 | Постановка задачи | 3 |
| 3 | Метрики качества результатов | 4 |
| 4 | Метрика SoftDCG | 6 |
| 5 | Метрика NoisedSoftDCG | 7 |
| 6 | Метрика FairSoftDCG | 8 |
| 7 | Применение результатов | 9 |
| 8 | Эксперименты | 10 |
| 8.1 | Зависимость гладкости от размера пула запросов | 10 |
| 8.2 | Зависимость качества аппроксимации от размера пула запросов | 11 |
| 8.3 | Изменение метрики при добавлении шума | 12 |
| 9 | Проблема выбора гиперпараметра | 13 |
| 10 | Выводы | 14 |
| | Список литературы | 15 |

Введение

Описание задачи ранжирования

Пусть имеется некий поисковый запрос. Задача ранжирования состоит в том, чтобы из списка всех доступных документов выбрать наиболее хорошие (релевантные) и показать их пользователю в поисковой выдаче. Для того, чтобы иметь возможность измерять качество алгоритма, выполняющего решение данной задачи, используются реальные оценки релевантности конкретных документов запросу, предоставленные людьми.

Обозначения

Обозначение 1.1. Обозначим $\{d_i\}_{i=1}^n$ - набор *документов* релевантных данному поисковому запросу; $\{r_i\}_{i=1}^n$ - *реальные оценки* данных документов, предоставленные ассессорами;

$\{s_i\}_{i=1}^n$ - оценки релевантности (*скоры*), выданные ранжирующим алгоритмом

Определение 1.1. Метрика качества ранжирования **DCG** определяется по формуле:

$$DCG = \sum_{i=1}^k \frac{r_{p_i}}{discount(i)}$$

где

p_1, \dots, p_n - перестановка на множестве $\{1, \dots, n\}$, т.ч. $s_{p_1} > s_{p_2} > \dots > s_{p_n}$

k - количество документов, по которым считается метрика ($k \leq n$) - важен в том случае, когда нас интересуют лишь несколько первых документов в выдаче

$discount(i)$ - дисконтирующий фактор, как правило $\frac{1}{i}$

Постановка задачи

Традиционные метрики ранжирования имеют конструкцию похожую на DCG: для подсчета метрики считается сумма по всем документам, *порядок* слагаемых в которой *зависит* от скоров, выданных ранжирующим алгоритмом, а *значения* - *нет*.

Несложно заметить, что для такой конструкции при фиксированном наборе документов и их оценок данная метрика может принимать лишь конечное количество различных значений. При этом изменение значения метрики происходит лишь в случае перестановки местами двух документов в выдаче.

Как было замечено выше, основная проблема подобных метрик в том, что они не имеют гладкой зависимости от скоров. В то же самое время логично ожидать, что, если ранжирующий алгоритм выдал трем документам оценки $\{100, 1, 0.5\}$, а другим трем документам - $\{10, 1, 0.5\}$, то он считает первый документ из первой тройки сильно лучшим, чем первый документ из второй тройки. В добавок, гладкая относительно скоров метрика является более чувствительным инструментом для оценивания качества алгоритма и отслеживания случаев недообучения или переобучения.

В данной работе исследуются разные подходы к построению метрик ранжирования, с целью получения метрики, которая бы удовлетворяла ряду свойств, вводимых далее

Метрики качества результатов

Хотелось бы, чтобы наша метрика обладала двумя свойствами. Во-первых, метрика должна быть "реалистичной". Т.е. ее локальные минимумы/максимумы должны соответствовать минимумам/максимумам DCG.

Определение 3.1. Пусть $\{y_i\}_{i=1}^k$ - значения метрики DCG на данном пуле запросов для k различных значений набора гиперпараметров. Пусть $\{\hat{y}_i\}_{i=1}^k$ - значения нашей метрики на том же пуле при тех же наборах гиперпараметров. Тогда **качеством аппроксимации** метрики DCG нашей метрикой назовем величину $\min_{\alpha, \beta} \frac{1}{k} \sum_{i=1}^k (y_i - \hat{y}_i)^2$

Обозначение 3.1. Далее будем обозначать *качество аппроксимации*, как $\text{approx}(\text{Metric Name})$

Также придуманная метрика должна быть гладкой. При этом необходим способ подсчета гладкости конкретной функции, если она задана не аналитически, а численно. Определим метрик гладкости.

Определение 3.2. Пусть $\{y_i\}_{i=1}^k$ - значения нашей метрики на данном пуле запросов для k различных значений набора гиперпараметров. Тогда **гладкостью** функции, посчитанной **через усреднение модуля разности** в соседних точках, будем называть величину

$$\text{smooth}_{\text{abs}}(y_1, \dots, y_k) = \sum_{i=2}^k |y_i - y_{i-1}| \cdot \frac{1}{|y_k - y_1|}$$

Определение 3.3. Пусть $\{y_i\}_{i=1}^k$ - значения нашей метрики на данном пуле запросов для k различных значений набора гиперпараметров. Тогда **гладкостью** функции, посчитанной **через нормировку дисперсии** разности в соседних точках, будем называть величину

$$\text{smooth}_{\text{std}}(y_1, \dots, y_k) = \frac{\text{diff}_{\text{std}}}{|\text{diff}_{\text{mean}}|}$$

Здесь $\text{diff}_{\text{mean}} = \frac{1}{k-1} \sum_{i=2}^k (y_i - y_{i-1})$, $\text{diff}_{\text{std}} = \frac{1}{k-1} \sum_{i=2}^k (y_i - y_{i-1} - \text{diff}_{\text{mean}})^2$

Определение 3.4. Пусть $\{y_i\}_{i=1}^k$ - значения нашей метрики на данном пуле запросов для k различных значений набора гиперпараметров. Пусть $\text{window} \in \mathbb{Z}, \text{deg} \in \mathbb{N}$. Тогда **гладкостью** функции, посчитанной **с помощью аппроксимации полиномами**, будем называть величину

$$\text{smooth}_{\text{poly}}(y_1, \dots, y_k) = \sum_{i=1}^{k-\text{window}+1} \frac{\left(\text{poly}_{\text{deg}}(y_i, \dots, y_{i+\text{window}-1})_{i+\lfloor \frac{\text{window}}{2} \rfloor} - y_{i+\lfloor \frac{\text{window}}{2} \rfloor} \right)^2}{k - \text{window}}$$

Здесь $\text{poly}_{\text{deg}}(y_i, \dots, y_{i+\text{window}-1})$ - аппроксимирующий полином степени deg , построенный по window точкам. Т.е. такой полином степени deg , что среднеквадратичное отклонение в точках $\{i, \dots, i + \text{window} - 1\}$ минимально.

В терминах данных нами определений, новая метрика тем лучше, чем меньше такие показатели, как гладкость и аппроксимация.

Возникает ряд проблем с тем, что выбор конкретного способа измерения гладкости для сравнения наших метрик между собой неочевиден. Первая метрика хорошо отображает

гладкость в том случае, если функция монотонна (если не учитывать шумовые колебания) - однако же в иных случаях данная метрика может быть плоха из-за нормировки на разность значений в крайних точках.

Вторая метрика ведет себя лучше, однако тоже не является достаточно гибкой и интерпретируемой.

С последней метрикой встает проблема выбора параметров deg и $window$. Тем не менее эта метрика понятна и действительно способна достаточно хорошо отображать гладкость функции. После перебора разных вариантов выбор был сделан в пользу параметров $deg = 4$, $window = 11$. При этом стоит учитывать, что гладкость метрики ранжирования измерялась на множествах размера порядка 100 точек.

Метрика SoftDCG

Рассмотрим метрику SoftDCG. Данная метрика является попыткой сглаживания метрики DCG. Кратко разберем способ подсчета SoftDCG

Пусть наш набор документов в поисковом запросе уже упорядочен по скорам. Рассмотрим конкретный документ d_j со скором s_j . Логично предположить, что скор не является точным определением того, на каком месте должен быть документ. Более точно: пусть $s_j - s_{j+1} < \varepsilon$, $s_{j-1} - s_j > \varepsilon$, тогда, если добавить к оценкам ранжирующего алгоритма случайный шум с дисперсией ε , документы s_j, s_{j+1} поменяются местами в выборке более вероятно, чем s_{j-1}, s_j . Данный факт говорит о близости документов, однако DCG способен учитывать близость документов с точностью до 1 места.

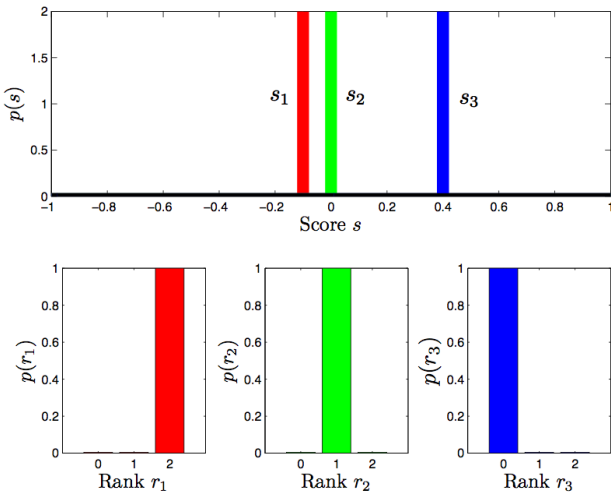


Figure 1: Deterministic scores and ranks: Three document scores as point (deterministic) values and their corresponding rank distributions. The lowest scoring document s_1 is certain to be ranked in the lowest position 2.

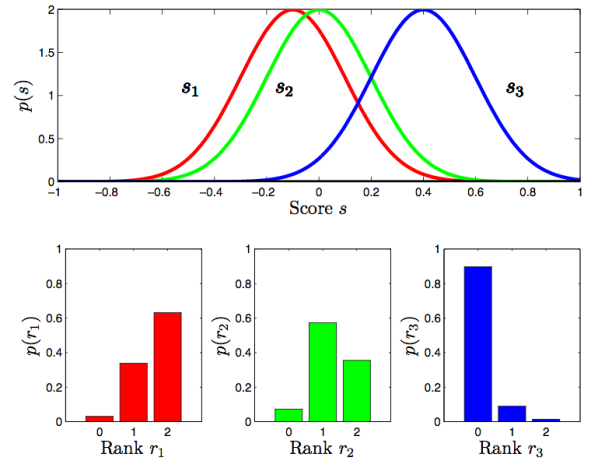


Figure 2: From score to rank distributions: Smoothed scores for 3 documents and the resulting 3 rank distributions.

Метрика SoftDCG предполагает следующее: вместо того, чтобы каждому документу сопоставлять конкретное место в поисковой выдаче, можно сопоставить ему нормальное распределение на местах. Параметры этого распределения подбираются по формулам исходя из скоров документов. Далее, зная распределение на местах, мы можем посчитать для каждого документа

$$\hat{d}(j) = E \text{ discount}(d_j) - \text{средний дискант } j\text{-го документа}$$

Далее эти средние дисканты используются для подсчета SoftDCG:

$$\text{SoftDCG} = \sum_{i=1}^n \hat{d}_j \cdot r_j$$

Метрика NoisedSoftDCG

Рассмотрим другую метрику (назовем ее NoisedSoftDCG). Идея данной метрики берет свое начало в статье про SoftDCG, однако способ подсчета данной метрики несколько иной.

В SoftDCG каждому документу сопоставлялось некоторое вероятностное распределение на множестве возможных занимаемых позиций. При этом следует отметить, что данное распределение вполне четко задавалось аналитически. Благодаря этому имелась возможность задать такой параметр, как $\hat{d}(j)$ (средний дискаунт), формулой.

В данном же случае при подсчете метрики принимается во внимание лишь тот факт, что при небольшом изменении скоров на случайные величины значение метрики может меняться в силу того, что близкие документы будут переставляться местами.

Алгоритм подсчета NoisedSoftDCG следующий:

- (1) Получим скоры ранжирующего алгоритма s_1, \dots, s_n
- (2) Сгенерируем случайный шум ξ_1, \dots, ξ_n
- (3) $\hat{s}_1 = s_1 + \xi_1, \dots, \hat{s}_n = s_n + \xi_n$
- (4) Посчитаем значение метрики $Value_{DCG}$
- (5) Повторим шаги (2)-(4) достаточно большое количество раз (Т) и вычислим

$$NoisedDCG = \sum_{i=1}^T Value_{DCG}^i$$

Можно дать некую интуицию по поводу того, почему метрика считается именно так. При достаточно большом Т близкие документы будут часто меняться местами, а усреднение DCG при этом даст некий аналог среднего дискаунта. Таким образом ожидается, что при больших Т данная метрика будет вести себя хорошо в плане гладкости

Метрика FairSoftDCG

Еще один вариант метрики, идея которой схожа с NoisedDCG. Заметим, что, основываясь на скорях, выданных ранжирующим алгоритмом, можно ввести вероятностное распределение на перестановках всех документов.

При этом распределение вводится так, что $P(d_i \text{ выше } d_j) \sim e^{\sigma(s_j - s_i)}$ (данное распределение можно ввести единственным образом). Благодаря этому для каждой перестановки на документах p_1, \dots, p_n можно посчитать ее вероятность:

$$P(p_1, \dots, p_n) = \prod_{i=1}^{n-1} \frac{e^{\sigma s_{p_i}}}{\sum_{k=j}^n e^{\sigma s_{p_j}}}$$

Теперь перебрав все перестановки документов можно посчитать "честное" мат. ожидание DCG. Собственно это у будет значением FairSoftDCG.

$$FairSoftDCG = \sum_{p_1, \dots, p_n} P(p_1, \dots, p_n) \cdot DCG(p_1, \dots, p_n)$$

При этом возникает ряд проблем с данной метрикой, т.к. вычислительно данная задача достаточно сложная (всего имеется $n!$ возможных перестановок). В связи с этим был выбран способ подсчета близкого к данной метрике значения - подсчета по топ-k документам:

$$FairSoftDCG = \sum_{p_1, \dots, p_k} P(p_1, \dots, p_k) \cdot DCG(p_1, \dots, p_k),$$

где сумма берется по всем возможным размещениям по k из n элементов

Применение результатов

Эксперименты

Зависимость гладкости от размера пула запросов

Зависимость качества аппроксимации от размера пула запросов

Изменение метрики при добавлении шума

Проблема выбора гиперпараметра

Выводы

Список литературы

- [1] M. Taylor, J. Guiver, S. Robertson and T. Minka. SoftRank: Optimising Non-Smooth Rank Metrics. Microsoft Research Cambridge, 2016
- [2] Christopher J.C. Burges. From RankNet to LambdaRank to LambdaMART. Microsoft Research Technical Report, 2010